

---

# Построение индекса сентиментов для анализа рынка акций

---

A Preprint

Бучко Даниил Владимирович  
Факультет Экономических Наук  
Студент, 3-ий курс бакалавриата  
НИУ ВШЭ, г. Москва  
dvbuchko@edu.hse.ru

Соколова Татьяна Владимировна  
Факультет Экономических Наук  
Старший преподаватель  
Базовая кафедра инфраструктуры финансовых рынков  
Аналитик в ЛАФР, НИУ ВШЭ, г. Москва  
tv.sokolova@hse.ru

3 июня 2020 г.

## Abstract

Когда заинтересованный исследователь попадает на финансовый рынок, для него открывается множество инструментов для принятия инвестиционных решений. Все эти инструменты в основе своей базируются на двух основополагающих источниках: на фундаментальной и технической информации. Использование данных из этих источников подразумевает не только первичную обработку, но и последующую интерпретацию полученных результатов, что является достаточно трудозатратным процессом. А что если есть иные источники информации, которые могут передавать содержательный смысл анализа общедоступных данных? Что если направлять усилия не на исследования состояния определенной компании, а попробовать прислушаться к тому, что говорят люди об этой компании? Может быть у нас получится получить общее представление о состоянии компании, основываясь на разрозненные мнения? В данном исследовании я проведу анализ альтернативных источников принятия решений и проверю их эффективность на примере российского рынка акций. В качестве таких источников будут выступать форумы и телеграм каналы.

## Вступление

Я бы хотел провести читателя этой статьи по пути вопросов и ответов, которые возникают сами собой в ходе решения любой поставленной задачи. Поэтому, сформулируем первый логичный вопрос: «Что мы хотим сделать?». Как было сказано ранее в абстракте, мы бы хотели получить полезную информацию о компаниях, торгующих ценными бумагами, не прибегая к трудозатратным операциям, предполагающим знания финансовой отчетности или технического анализа. Следующий логичный вопрос: «Что это за информация и почему её можно считать ценной?» Частично на этот вопрос мы ответим в главе 1, где планируется выбрать данные и определиться с их источниками, а частично — в главе 4, где определимся с тем, насколько ценной оказалась полученная информация. В главе 1 я также рассмотрю особенности и способы получения данных. Будет показано на примерах, как выглядит структура источников, каким образом осуществляется автоматический сбор и обработка данных. Затем полученные данные мы начнем активно исследовать в главе 2, чтобы ответить на следующий вопрос: «Как использовать полученные данные?» При подробном рассмотрении я опишу основные тонкости и механизмы предобработки полученных текстов, покажу особенности конкретно наших данных, посчитаю статистики и визуализирую основные результаты. В главе 3 мы займемся вопросами непосредственного моделирования языка при помощи машинного обучения и нейронных сетей: сформулируем задачу, выберем метрики, а затем подберем подходящую модель.

## 1 Получение данных.

Какие данные использовать?

Информацию об окружающем мире можно черпать из различных источников. Очевидно, что любой источник информационного потока имеет свои особенности и отличительные черты. К примеру, информация, публикуемая в журналах, обычно проходит через долгие корректировки, и к моменту выпуска издания, она может частично или полностью исказиться, утрачивать свою значимость и актуальность, в зависимости от задачи, в которой эта информация планировалась использоваться. Аналогичными свойствами можно охарактеризовать информацию, получаемую из новостей, регулярных аналитических сводок и стриминговых сервисов. Более того, важной отличительной чертой всех этих источников является то, что информация, получаемая на выходе, проходит через множество рук и любые конкурентные преимущества связанные с ценностью новой информации могут быть утеряны, потому что всегда будет некий посредник между исследователем и событиями.

Поэтому, для нашей задачи, — оперативно получать потенциально полезную информацию о финансовом рынке — необходимо выбрать источники, обладающие подходящими свойствами:

1. Релевантность. Важнее всего, чтобы информация с нашего источника имела отношение к ценным бумагам и гипотетически имела предсказательную силу. Ведь именно для этого мы и собираемся её собирать и обрабатывать. Отсекаем любые неэкономические источники данных.
2. Доступность. Это свойство позволит оперативно получать факты об изменениях на рынке без дополнительных ограничений, накладываемых посредниками или высокими издержками. Исключаем источники данных, за которые необходимо платить.
3. Высокая частотность данных. Очень удобно выбирать такой источник, информация с которого была бы в достаточном количестве, для проведения простейшего статистического анализа. Кроме этого, это свойство дает возможность моментально адаптироваться к любым шокам, меняющим конъюктуру рынка ценных бумаг. Концентрируемся на постоянно обновляющихся, высокочастотных источниках данных.

Учитывая все аспекты, приведенные выше, я решил остановиться на текстовых источниках данных. Релевантность конкретизируется в текстовых данных, описывающих ситуацию на рынке акций. Как быть с доступностью? Здесь можно выбрать источники, не требующие денежных и временных издержек на ожидание получения информации — финансовые форумы и группы в социальных сетях. Заметим, что такие источники удовлетворяют и последнему свойству — свойству высокой частотности. Многие онлайн-платформы, ставшие привычным местом для обсуждения инвестиционных идей и стратегий существуют на российском рынке аж с конца 2000-х годов и активно развиваются по сей день.

### 1.1 Интернет сообщества: сайты

Безусловным лидером на на российском рынке финансовой информации является интернет платформа MFD. Судя по информации об интернет-ресурсе<sup>1</sup>, эта платформа работает с 1996 года и объединяет ежедневно более 10000 человек. Вторым кандидатом на подходящий источник информации является интернет сообщество Smart-Lab. Помимо указанных ресурсов, существует несколько интересных организаций, предоставляющих финансовую информацию, среди них: Cbonds, Quote РБК, InvestFunds. Единственное отличие последних состоит в том, что они работают по принципу предоставления контента, а значит не до конца удовлетворяют нашей предпосылке о доступности. Остановимся на MFD.

### 1.2 Интернет сообщества: телеграм каналы

Telegram-каналы стали популярны на пике введения блокировок в результате отказа основателя компании от предоставления ключей шифрования государству<sup>2</sup>. Сложно судить, что стало ключевым фактором в успехе телеграма, будь то зажигающая идея противостояния государству, которую так любит молодежь, либо удобный интерфейс, но телеграм полюбили и не обошли стороной люди, имеющие непосредственное отношение к финансовым рынкам. Так или иначе, телеграм предоставляет удобный и простой способ обсуждения различных тематик, поэтому запомним этот источник информации

<sup>1</sup><https://mfd.ru/about/>

<sup>2</sup><https://www.sostav.ru/publication/telegram-38688.html>

как задел на будущие исследования и вернемся к его обсуждению в заключительной секции этого исследования.

Итак, мы разобрались с тем, что интернет площадка MFD обладает всеми необходимыми для нашего исследования характеристиками. Следующий вопрос: «Какую конкретно информацию, мы собираемся использовать?». Существуют многочисленные исследования в области анализа влияния текстовой информации на изменение в доходности ценных бумаг<sup>3</sup>. В данных исследованиях проверялась гипотеза о влиянии социальных сетей на доходность акций и индексов. Более того, были предприняты успешные попытки построить регрессионные модели, объясняющие доходность индексов, ориентируясь только на сентименты сообщений в социальных сетях. Попробуем сделать подобное исследование, но с использованием более современного подхода в области моделирования языка и на российском рынке акций.

### 1.3 Сбор информации с интернет-ресурсов

Поскольку мы определились с тем, что и откуда будем собирать, настало время понять, каким образом выполнить эту задачу. Для этого нужно получить представление о строении сайтов и понять, из каких деталей состоят веб-страницы. Ниже можно видеть переписку участников финансового форума в той форме, в которой её видит человек и в том облики, в каком она предстает перед браузером.



Рис. 1: Каким образом информация предоставлена на сайте

Заметим, что каждое сообщение находится в соответствующем блоке (контейнере). Таким блокам присваивается метка «message», явно указывающая на содержимое контейнера. Весь процесс сбора данных состоит в том, чтобы отыскать все контейнеры на странице, получить их содержимое и перейти к следующей странице. Обратим внимание на то, как хорошо структурирована информация на этом примере. В реальности сайты редко бывают статическими, обычно они меняют свою структуру под воздействием пользовательский действий. Но это явно не случай российских форумов, написанных с конца 90-х годов. Кроме того, нужно с осторожностью пользоваться автоматическим сбором данных. Некоторые сайты запрещают использование парсеров, потому что слишком частые запросы страниц нагружают сервера и неправильно написанный код может значительно затруднить пропускную способность интернет-ресурса. Переходим к следующему шагу.

<sup>3</sup>Работы [1], [2], [3] в списке литературы

Таблица 1: Примеры полученных сообщений

Дата сообщения	Имя пользователя	Текст сообщения
09.11.2014 15:46	Веном	ШОРТИТЕ!!!
09.11.2014 17:17	михаил2	ты первый
09.11.2014 17:43	петрович	Так вы будете бить рекорд погружения или как?
09.11.2014 18:09	Веном	Рубль непоколебим в России. Доллар растёт
09.11.2014 18:27	capitan	Начинайте мне еще пару тысяч прикупить надо...
10.11.2014 14:33	capitan	Прикупил себе PLZL.
10.11.2014 15:47	capitan	Главное не слейся раньше времени как на Алросе) хотя я и сам так сделал)
10.11.2014 16:37	драконорожденный	Не не сольюсь. А с Алросой я ошибку сделал. Надо было смотреть на то
11.11.2014 11:36	драконорожденный	Думаю что эту цену мы увидим не раньше следующей весны...Я предупреждал
14.11.2014 22:52	МарКс	Все после таких новостей понятно стало
15.11.2014 22:59	трейдерсрублевки	<a href="http://oilru.com/news/436599/">http://oilru.com/news/436599/</a>

## 2 Подготовка данных

В результате сбора данных были получены сообщения с 2008 по 2020 год по компаниям из разных групп капитализаций: маленькие, средние и большие. (см. примеры Таблица 1). Перед тем, как перейти к процессу построения моделей, необходимо предобработать текст таким образом, чтобы максимально исключить всю лишнюю информацию. Для этого текст, при помощи регулярных выражений, очищается от любой пунктуации, любых небуквенных символов, лишних пробелов и неинформативных ссылок и слов. После этого, каждое предложение приводится к нижнему регистру, лемматизируется (то есть приводится к своей начальной форме) и стеммингуется (обрезается таким образом, чтобы от слова осталась только его основа). Произведенные операции позволяют сократить количество неинформативных признаков, тем самым улучшая скорость и точность работы оптимизационных алгоритмов. В результате подобной обработки, сообщения стали иметь следующий вид:

Таблица 2: Сообщения после обработки

Дата сообщения	Имя пользователя	Текст сообщения
09.11.2014 15:46	Веном	шорт
09.11.2014 17:17	михаил2	ты перв
09.11.2014 17:43	петрович	так вы быт бит рекорд погружен ил как
09.11.2014 18:09	Веном	рубл непоколебим в росс доллар раст
09.11.2014 18:27	capitan	начина я ещ пар тысяч прикупа
10.11.2014 14:33	capitan	прикупа себ plzl
10.11.2014 15:47	capitan	главн не слива ран врем как на алрос хот я и сам так сдела
10.11.2014 16:37	драконорожденный	не не слива а с алрос я ошибк сдела быт смотрет на то
11.11.2014 11:36	драконорожденный	дума что этот цен мы увидет не ран след весн я предупрежда
14.11.2014 22:52	МарКс	посл так новост понятн станов
15.11.2014 22:59	трейдерсрублевки	

Обратим внимание на то, что сообщения в большинстве случаев не потеряли свой основной смысл, однако количество уникальных слов сократилось в 4 раза: с 131,530 до 34,733. Такой подход в обработке текстов имеет свои ограничения, и иногда останавливаются на этапе лемматизации, но как мы увидим далее, именно такой способ подготовки сообщений позволит делать наиболее точные прогнозы в рамках конкретно нашей задачи. В приложении можно посмотреть на другие интересные статистики по датасету (см. Главу 5).

Как можно видеть из рисунка 2, в результате обработки данных частотность слов распределилась более равномерно, уменьшая долю выбросов в выборке. На изображении не попали слова с очень низкой




Рис. 2: Распределение слов в тренировочном наборе данных

частотностью, для сохранения наглядности. В приложении есть таблица 3, показывающая примеры частоупотребляемых и редкоупотребляемых слов. Переходим к выбору модели.

### 3 Выбор модели

Следующий момент, который мы должны для себя решить — как использовать собранные данные? В работах [1], [2] авторы предпринимали попытки объяснить доходность бумаг, исходя из гипотезы, которую можно сформулировать следующим образом: «Эмоциональный фон, складывающийся вокруг определенной бумаги, влияет на решение инвестора (по крайней мере частного) о покупке или продаже той или иной бумаги». Для того чтобы проверить эту гипотезу, нам необходимо построить модель  $F(\cdot)$ , которая бы переводила сообщения во множество эмоциональных признаков по следующей схеме:

$$F(\text{сообщение}) = \begin{cases} 3, & \text{если сообщение носит позитивный окрас} \\ 2, & \text{если сообщение не относится к финансовому рынку} \\ 1, & \text{если сообщение носит негативный эмоциональный окрас} \end{cases}$$

Получается, что для нас, как для исследователей, задача сводится к построению модели, разделяющей все сообщения на 3 группы. С точки зрения машинного обучения, такая задача именуется задачей классификации. Выделим ключевые особенности нашего набора данных, чтобы выбрать подходящую модель:

1. Изменчивость лексики во времени. Некоторые фразы, под влиянием различных культурных особенностей, меняют со временем то, как мы выражаем свои мысли, поэтому из всего количества собранных данных, для обучения были взяты сообщения из различных временных промежутков.
2. Постобработанные данные не имеют меток класса. Простым языком, чтобы использовать алгоритмы обучения с учителем, нам необходимо дополнительно вручную разметить данные. Особенности рутинной ручной разметки ограничивают количество данных для обучения, поэтому из этого пункта возникает следующая характерная черта.
3. Относительно небольшой датасет. В результате разметки совместными усилиями с группой единомышленников был сформирован итоговый датасет, состоящий из 30,000 наблюдений.
4. Несбалансированность классов. Очень важная черта, которую обязательно необходимо иметь в виду, при построении любой модели. В наших данных после разметки, распределение классов имело вид, изображенный на рисунке 3

Особенности 3-4, обсуждаемые выше, будут активно приниматься во внимание при построении моделей.




Рис. 3: Распределение категорий в тренировочном наборе данных

### 3.1 Представление данных

Чтобы построить классификатор сообщений, нужно представить данные, понятным компьютеру образом. Более формально, нам необходимо определить пространство, из которого искомая модель  $F(\cdot)$  будет переводить сообщения в соответствующие сентиментам классы. Имея численное представление каждого из предложений, можно применять математический аппарат к построению моделей. Принимая во внимание методы машинного обучения и статистики, такие представления могут задаваться самыми различными способами. В ходе исследования мы будем постепенно двигаться от простейших к более продвинутым, попутно делая выводы о преимуществах и недостатках каждого из подходов.

#### 3.1.1 OneHotEncoding

OneHotEncoding — один из множества способов определения множества значений, на котором будет работать искомая модель  $F(\cdot)$ . Суть метода заключается в создании дамми-переменных в количестве, равном количеству слов в датасете. Таким образом, каждое сообщение можно закодировать вектором, состоящим из нулей и единиц. Единицы будут характеризовать наличие определенного слова, а нули — отсутствие. Такой подход накладывает свои ограничения, среди которых:

1. Необходимость хранения в оперативной памяти большого объема данных в процессе обучения алгоритма. В нашем случае, размер датасета, закодированного таким образом, имел бы размерность

$$R_{\text{Количество сообщений} \times \text{Количество слов}} = R_{31000 \times 34733}$$

2. Учитывая, что каждое слово кодируется единицей, получаем, что все слова имеют одинаковый вес. Однако, в русском языке некоторые слова встречаются гораздо чаще других, и их большее количество в тренировочных данных будет накладывать отпечаток на процесс оптимизации, о котором речь пойдет ниже. В качестве шага предобработки были предприняты меры по уменьшению количества лишних слов, но как можно видеть в таблице 3, среди наиболее употребительных слов все еще мелькают слова, не влияющие на сентимент сообщения.

#### 3.1.2 Tf-Idf Encoding

Tf-Idf — решение проблемы равновзвешивания слов в процессе оптими

## 4 Тестирование полученной информации

dwadlwmdmawd

## 5 Приложение

adownawdnaodin

Таблица 3: Частотность первых и последних 20 слов после обработки

Слово	Частотность слова	Слово	Частотность слова
не	13517	marketbeat	1
а	6964	bmo	1
эт	4206	canad	1
год	2402	raymond	1
шорт	1807	james	1
быт	1654	canaccord	1
сегодня	1626	genuit	1
ден	1626	cibc	1
так	1517	mull	1
нефт	1507	торонт	1
рост	1499	акр	1
цен	1442	мобилизова	1
акц	1334	скептичн	1
дума	1265	финанасов	1
пок	1241	недопустим	1
див	1219	гсп	1
рынок	1184	xi	1
дава	1163	неаффилирова	1
сво	1159	неаффилирован	1
компан	1059	несоответств	1

## Список литературы

- [1] Nuno Oliveira, Paulo Cortez, Nelson Areal. The impact of microblogging data for stock market prediction: Using Twitter to predict returns, volatility, trading volume and survey sentiment indices In Expert Systems With Applications 73 (2017), pages 125–144.
- [2] Thomas Renault. Intraday online investor sentiment and return patterns in the U.S. stock market In Journal of Banking and Finance, 2017 84th, pages 25–40. .
- [3] Thi-Thu Nguyen and Seokhoon Yoon. A Novel Approach to Short-Term Stock Price Movement Prediction using Transfer Learning In Journal Applied Sciences, 2019 9th, pages 3–16.